

サポートベクトルマシン

6/1 ゼミ

加藤万理子


サポートベクトルマシン

- 分類を行うモデルのひとつ
- 今回は説明として2値分類について述べる
- 回帰や多クラス分類にも使える

サポートベクトルマシン

ちょうど真ん中を通る直線を引き
きたい

→ 「点と直線の距離」の式か
ら、最適な直線を導く




サポートベクトルマシン

- 直線で分離が可能

→ 一番近いデータまでの距離をハードマージンという

- 直線では分離が不可能

→ 誤判定を許す幅をソフトマージンという



定義

訓練集合： $\left\{ (x_i, y_i) \right\}_{i \in [n]}$

説明変数： $x_i \in \mathbb{R}^d$

ラベル： $y_i \in \{-1, 1\}$

決定関数： $f(x) = \beta^T \mathbf{x} + b \quad f: \mathbb{R}^d \rightarrow \mathbb{R}$

分類器： $g(x) = \begin{cases} 1 & f(x) > 0 \\ -1 & f(x) < 0 \end{cases}$

つなぎ

- $g(x)$ の定義より、 $f(x) = 0$ が境目になっている。

→分類境界

- 正しく分類できているとき $y_i f(x_i) \geq 0$ がすべての i で成立することに注意する

w, b を推定していく

点と直線の距離

命題23 より、平面 $\beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p = 0$ と $x = [x_1, \cdots, x_p]$ として、

$$d(x) := \frac{\left| \beta_0 + x_1 \beta_1 + \cdots + x_p \beta_p \right|}{\sqrt{\beta_1^2 + \cdots + \beta_p^2}}$$

となる。

点と直線の距離


$$d(x) := \frac{\left| \beta_0 + x_1\beta_1 + \cdots + x_p\beta_p \right|}{\sqrt{\beta_1^2 + \cdots + \beta_p^2}}$$

ある x_i から分類境界までの距離は

$$\frac{\left| \beta^T \mathbf{x}_i + b \right|}{\|\beta\|}$$

である。

マージン最適化の表現



マージン最適化の表現

ある正の実数 $M > 0$ に対して $y_i f(x_i) \geq M$ がすべての i で成立するとする。

$$\max_{\beta, b, M} \frac{y_i(\beta^T \mathbf{x}_i + b)}{\|\beta\|}$$

$$s.t. \quad y_i(\beta^T \mathbf{x}_i + b) \geq M, \quad i \in [n]$$

マージン最適化の表現

最大化するには M はすべての事例に対する制約条件の値のうち、
最小の値とおなじになる。そのような i を i' とすると、

$$\frac{M}{\|\beta\|} = \frac{y_{i'}(\beta^T \mathbf{x}_{i'} + b)}{\|\beta\|}$$

マージン最適化の表現

$\|\beta\|_2 = 1$ であることを仮定すると、

$$\max_{i=1,\dots,N} y_{i'}(\beta^T \mathbf{x}_{i'} + b)$$

を求める問題となる。

ソフトマージン

分離不可では制約条件 $y_i(\beta^T \mathbf{x}_i + b) \geq M$ を緩和することで導かれる。

$$\frac{y_i(\beta^T \mathbf{x}_i + b)}{M} \geq 1$$


ここで新たに変数 $\varepsilon_i \geq 0, i \in [n]$ を導入する。

$$\frac{y_i(\beta^T \mathbf{x}_i + b)}{M} \geq 1 - \varepsilon_i$$

$$y_i(\beta^T \mathbf{x}_i + b) \geq M(1 - \varepsilon_i)$$

ソフトマージン

マージンと別に変数を導入することで、以下のように分類境界から外れているデータについても考えることができる。



ソフトマージンでの誤分類

誤分類が起こるとき、

$$y_i(\beta^T \mathbf{x}_i + b) < 0$$

より、以下である必要がある。

$$\varepsilon_i > 1$$

このことから、ある整数 γ について

$$\sum_{i \in [n]} \varepsilon_i \leq \gamma$$

であれば、誤分類の数も γ 以下であるとわかる。

主問題（ソフトマージン）

$$\min_{\varepsilon, \beta, b} \frac{1}{2} \|\beta\|^2 + C \sum_{i \in [n]} \varepsilon_i$$

$$s.t. \quad y_i(\beta^T x_i + b) \geq 1 - \varepsilon_i,$$

$$i \in [n], \quad \varepsilon_i \geq 0$$

C は正則化係数と呼ばれる正の係数で、事前に値を決めるもの。

ラグランジュ関数

$$L_p = \frac{1}{2}\|\beta\|^2 + C \sum_{i=1}^N \epsilon_i - \sum_{i=1}^N \alpha_i \{y_i(\beta_0 + x_i\beta) - (1 - \epsilon_i)\} - \sum_{i=1}^N \mu_i \epsilon_i$$

α_i, μ_i はラグランジュ係数/双対係数という。 $\|\beta\|$ を最小にすること

は、 M を最大化することに相当する。

主問題と双対問題

ラグランジュ関数について、以下が主問題と等価である。

$$\min_{\beta, b, \varepsilon} \max_{\alpha \geq 0, \mu \geq 0} L(\beta, b, \varepsilon, \alpha, \mu)$$

以下は双対問題と呼ばれる。

$$\max_{\alpha \geq 0, \mu \geq 0} \min_{\beta, b, \varepsilon} L(\beta, b, \varepsilon, \alpha, \mu)$$

主問題と双対問題

基本、最適化問題では、双対関数の値は、主問題の最適値を超えない

- SVMでは主問題と双対問題の目的関数値が最適解において一致
- 双対問題のほうが解きやすかったり、非線形化を見据えられたりするのでこちらを解く

KKT条件(Karush-Kuhn-Tucker)

- 解の最適性を判定するための条件
- 不等式を含む最適化問題を解くときに使う
- SVMではKKT条件が必要十分条件である

定義

シンプルなラグランジュ関数を定義する。

まず、想定する問題は

$$\begin{aligned} & \min_{\beta} f_0(\beta) \\ & s.t. \quad f_j(\beta) \leq 0, \quad j = 1, \dots, m \end{aligned}$$

最適解が β^* であるとする。このときラグランジュ関数は

$$L(\alpha, \beta) = f_0(\beta) + \sum_{j=1}^m \alpha_j f_j(\beta)$$

命題24 KKT条件

β^* を最適解とする。 $f_1(\beta) \leq 0, \dots, f_m(\beta) \leq 0$ もとで、 $\beta = \beta^* \in \mathbb{R}^p$ が $f_0(\beta)$ を最小にすることと、

$$f_1(\beta^*), \dots, f_m(\beta^*) \leq 0$$

であって、

$$\alpha_1 f_1(\beta^*) = \dots = \alpha_m f_m(\beta^*) = 0$$

$$\nabla f_0(\beta^*) + \sum_{i=1}^m \alpha_i \nabla f_i(\beta^*) = 0$$

を満足する $\alpha_1, \dots, \alpha_m \geq 0$ が存在することは同値である。

KKT条件

必要十分の証明

双対問題

$$\max_{\alpha} -\frac{1}{2} \sum_{i,j \in [n]} \alpha_i \alpha_j y_i y_j x_i^T x_j + \sum_{i \in [n]} \alpha_i$$

$$s.t. \quad \sum_{i \in [n]} \alpha_i y_i = 0$$

$$0 \leq \alpha_i \leq C, \quad i \in [n]$$

命題25

$$\alpha_i = 0 \iff y_i(\beta_0 + x_i\beta) > 1 \text{ (外側)}$$

$$0 < \alpha < C \implies y_i(\beta_0 + x_i\beta) = 1 \text{ (上)}$$

$$\alpha_i = C \iff y_i(\beta_0 + x_i\beta) < 1 \text{ (内側)}$$

aからわかる位置関係




図 1.6 マージンの内側・マージン上・マージンの外側.

cvxoptを使ったSVMの実装

Pythonのcvxoptというライブラリを使う。cvxoptでは以下のような形の問題を想定している。

$$\min -\frac{1}{2}x^T Px + q^T x$$

$$s.t. \quad Gx \leq h$$

$$Ax = b$$

cvxoptを使ったSVMの実装

$$z = \begin{bmatrix} x_{1,1}y_1 & \cdots & x_{1,p}y_1 \\ \vdots & \ddots & \vdots \\ x_{N,1}y_N & \cdots & x_{N,p}y_N \end{bmatrix} \in \mathbb{R}^{N \times p}, \quad G = \begin{bmatrix} 1 & \cdots & 0 \\ 0 & \ddots & 0 \\ 0 & \cdots & 1 \\ -1 & \cdots & 0 \\ 0 & \ddots & 0 \\ 0 & \cdots & -1 \end{bmatrix} \in \mathbb{R}^{2N \times N}$$

cvxoptを使ったSVMの実装

$$P = -zz^T \in \mathbb{R}^{N \times N}$$


$$h = [C, \dots, C, 0, \dots, 0]^T \in \mathbb{R}^{2N+1}$$

$$x = [x_1, \dots, x_N] \in \mathbb{R}^N$$

$$A = [-y_1, \dots, -y_N] \in \mathbb{R}^{1 \times N}$$

$$b \in \mathbb{R}$$

cvxoptを使ったSVMの実装



カーネル法を使った拡張





図 1.8 写像 ϕ が非線形な場合，入力 \mathbf{x} の空間（左）では決定関数 $f(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) + b$ は非線形な分類境界を形成します．一方， $f(\mathbf{x})$ は $\phi(\mathbf{x})$ に関しては 1 次なため $\phi(\mathbf{x})$ の空間 \mathcal{F} （右）では線形な分類境界として表現されています．

カーネル法を使った拡張

– カーネル法の概念図



特徴空間で線形データ解析を施す!

e.g. SVM

カーネル法を使った拡張

$$f(x) = \boldsymbol{w}^T \boldsymbol{x} + b$$

について、入力 x を何らかの特徴空間 F へ写像する関数を考える。

$$\phi : \mathbb{R}^d \rightarrow F$$

この $\phi(x)$ を新たな特徴ベクトルと解釈すると、

$$f(x) = w^T \phi(x) + b$$

新たな特徴ベクトルを使い双対問題を考える

$$\begin{aligned} \max_{\alpha} \quad & -\frac{1}{2} \sum_{i,j \in [n]} \alpha_i \alpha_j y_i y_j \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j) + \sum_{i \in [n]} \alpha_i \\ \text{s.t.} \quad & \sum_{i \in [n]} \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C, \quad i \in [n] \end{aligned}$$

カーネル関数の定義

注目すべきは $\phi(x_i)^T \phi(x_j)$ という内積の形でのみであること。ここで、内積をカーネル関数として以下のように定義する。

$$K(x_i, x_j) = \phi(x_i)^T \phi(x_j)$$

内積は以下のような形でも表現できる。


$$\langle \phi(x_i), \phi(x_j) \rangle$$

内積以外のカーネル

多項式カーネル(d次元)

$$K(x, y) = (1 + x^T y)^d$$

線形カーネルと非線形カーネルでの境界




sklearnのSVMを用いる

Radial Basis Function(RBF/ガウスカーネル/ラジアルカーネル)

$$k(x, y) = \exp \left\{ -\frac{1}{2\sigma^2} \| x - y \|^2 \right\}$$

sklearnのSVMを用いる



ハイパーパラメータチューニングを行う

